

作业三：大数据存储和处理与 MovieLens 落地架构

本文承接作业二已经确认的问题与设计决策，形成“P/D来源 → 数据对象与访问需求 → 课堂技术 → 工业演进 → 技术选型 → 落地架构”的推理链。当前版本已形成T1—T4可交接初稿；未完成实验验证的能力均按目标设计、回退方案或远期设想标注。

3.1 输入与追踪关系

为避免导出 PDF 时横向表格换页错乱，以下改为按技术选型逐项纵向展开。

T1：批量主存储与版本化目录

项目	内容
来源	P1、P3、D1，并关联P2、D2。
所需能力与约束	批量大文件需顺序读写、按版本定位并在节点故障后判断可用性；数据分级保护，正式版本不可覆盖。
候选技术	本地文件；HDFS；对象存储。格式子候选包括Text、Parquet、ORC。
比较维度	容错、吞吐、数据本地性、版本隔离、恢复与运维成本；格式保真、列裁剪、压缩、模式和兼容性。
最终选择	HDFS版本化目录为批量主存储；raw经staging校验后rename，rules及被采用的quarantine/clean/metrics/reports各存稳定对象，publish仅存manifest。
选择理由	HDFS适合Hadoop大文件批处理和不可变快照；原文便于追溯，Parquet利于列裁剪和聚合。
未满足项与补救措施	多节点、副本及Parquet链路未验证，实验回退HDFS文本+MapReduce；业务发布由manifest校验和B侧MySQL补足，存算分离成为需求时重评对象存储。

T2：批量SQL访问层

项目	内容
来源	P2、P3、D2，并关联P1、D1。
所需能力与约束	按版本和任务定位正式数据，支持批量SQL扫描、聚合、历史比较；事务更新与分析分离。
候选技术	Hive外部表；HBase；MySQL；Elasticsearch。
比较维度	扫描聚合、点查更新、全文检索、事务一致性、HDFS复用、分区裁剪、运维成本。
最终选择	Hive外部表提供HDFS批量SQL，按已知查询键分区、当前不分桶；MySQL发布后异步登记分区；不引入HBase和Elasticsearch。
选择理由	Hive复用HDFS文件并提供模式和SQL；MySQL是唯一发布边界，Hive只作可重建分析访问层。
未满足项与补救措施	Hive登记可重试并允许短暂查询滞后，失败不回滚SUCCESS；链路未验证时MapReduce直读文本，出现在线点查、持续更新或全文搜索时重评HBase和Elasticsearch。

T3：异步治理批处理

项目	内容
来源	P4、P5、D3。
所需能力与约束	可切分、可观测、可恢复的异步批处理；支持Shuffle、失败尝试识别和受控重试。
候选技术	本地脚本；MapReduce on YARN；Kubernetes Job；托管弹性服务。
比较维度	切分与Shuffle、数据本地性、失败恢复、状态与日志、课程匹配、运维和弹性。
最终选择	目标架构采用Hadoop MapReduce on YARN；当前仅验证过Hadoop本地模式，YARN链路待实验验证。
选择理由	MapReduce提供切分、Shuffle、任务尝试、计数器和输出提交；YARN提供资源调度和运行状态，符合批量治理及课程要求。

项目	内容
未满足项与补救措施	YARN尚未实测；启动和多阶段落盘开销较高；倾斜与慢任务不会自动消失。后续验证YARN提交、状态和日志，采用异步接口并观测阶段耗时、分区数据量和Shuffle指标；出现独立实时需求或明显潮汐负载后再重评其他方案。

T4：可信发布与正式可见性

项目	内容
来源	P5、P6、D4。
所需能力与约束	候选与正式结果隔离；任务/尝试可查询；迟到尝试不可覆盖；发布幂等；Agent只读正式结果。
候选技术	仅HDFS目录；HBase；MySQL InnoDB+HDFS；仅YARN历史状态。
比较维度	事务与唯一约束、点查更新、并发尝试、数据体量、日志吞吐、运维成本。
最终选择	MySQL InnoDB保存任务、尝试和发布记录； HDFS稳定目录保存被采用数据与报告，publish/{result_id}/manifest.json 只存清单。
选择理由	MySQL负责事务可见性，HDFS适合不可变大对象；manifest以版本、路径和校验信息引用稳定对象，不复制大产物。
未满足项与补救措施	HDFS与MySQL无跨系统事务；先形成并校验稳定对象和manifest， 再事务登记published_result/accepted_attempt_id/SUCCESS，未登记对象不可见并按人工流程清理； 后续再评估高可用或更强协调。

3.2 数据对象与访问需求

A负责的数据对象

技术选型T1/T2分别采用HDFS版本化目录和Hive外表表，不同于训练/验证时间边界字段 train_cutoff_t1、validation_cutoff_t2；A定义 raw/quarantine/clean/metrics 稳定数据目录及独立rules目录，B负责work候选隔离、reports稳定报告、publish manifest、正式可见性、状态和日志；Parquet/Hive未验证时回退HDFS文本+MapReduce直读。

以下按数据对象逐项展开，统一采用“项目/内容”的纵向结构，减少导出时表格横向溢出。

MovieLens原始文件（ ratings.dat 、 movies.dat 、 users.dat ）

项目	内容
数据角色	权威源数据，是清洗、复算和追溯起点。
主存储与格式	HDFS正式目录 /movielens/raw/{dataset_version}/ ； 暂存目录 /movielens/raw/.staging/{dataset_version}/ 。保留原始 .dat 和ISO-8859-1编码，manifest记录三文件、版本及校验信息。
写入模式	上传三文件至staging，检查齐全、大小、编码和校验和，最后写manifest，再在同一HDFS内rename至正式目录；正式目录已存在则拒绝覆盖。
读取模式	MapReduce只全量读取存在有效manifest的正式目录，不读取staging。
一致性要求	manifest与三文件校验通过且rename完成后才可用；半上传不得被任务读取。
生命周期	正式raw保留到课程项目结束，无自动TTL或版本上限；失败staging确认未形成正式版本后人工删除。
对应P/D/T	P1、P2、P3； D1、D2； T1。

解析失败或规则判定异常的记录

项目	内容
数据角色	隔离证据和可复核派生数据，不是清洗后正式数据。

项目	内容
主存储与格式	候选位于HDFS /movielens/work/{task_id}/{attempt_id}/quarantine/ ；被采用后稳定路径为 /movielens/quarantine/{task_id}/ 。建议使用JSON Lines或带明确转义的文本，保存原始行、来源文件、失败原因和 attempt_id 等处理证据。
写入模式	由清洗任务按attempt批量写候选；采用时形成不可变稳定目录，不在正式目录追加。
读取模式	按 task_id 读取正式异常统计和样例，必要时按来源文件或异常原因扫描；执行排障才按 attempt_id 读取候选。
一致性要求	失败attempt不可混入正式证据；只有被采用attempt的记录可被正式报告引用；重复执行不得重复计入正式指标。
生命周期	正式manifest引用者保留到课程项目结束；work候选按统一人工删除流程处理。
对应P/D/T	P1、P2、P3；D1、D2；T1。

清洗后的 ratings

项目	内容
数据角色	正式派生数据，供后续评分预测及行为分析使用。
主存储与格式	HDFS /movielens/clean/{dataset_version}/{task_id}/ratings/ ；目标格式为Parquet，未验证时用带明确模式的文本；字段仅为 UserID、MovieID、Rating、Timestamp ，不重复保存任务时间边界。
写入模式	MapReduce先写 work/{task_id}/{attempt_id}/clean/ratings/ ；校验并采用后形成不可变稳定目录，不追加、不原地更新。
读取模式	MapReduce全量扫描；目标Hive外部表用于按用户/电影聚合及时间范围过滤。
一致性要求	必须与同一 dataset_version 、 rule_version 、 task_id 和被采用attempt的 movies/users 、指标成组可见；不得发布部分文件。
生命周期	正式manifest引用者保留到课程项目结束，无自动TTL或版本上限；候选按统一流程清理。
对应P/D/T	P1、P2、P3；D1、D2；T1、T2。

清洗后的 movies

项目	内容
数据角色	正式派生数据，提供电影标题和类型维度。
主存储与格式	HDFS /movielens/clean/{dataset_version}/{task_id}/movies/ ；目标格式为Parquet，未验证时回退文本；字段仅为 MovieID、Title、Genres ， Genres 保留原有竖线分隔语义。
写入模式	先写 work 中本attempt的 clean/movies/ ，采用后形成不可变稳定目录。
读取模式	MapReduce全量扫描、按 MovieID 关联；目标Hive用于SQL关联，类型拆分仅在计算时进行。
一致性要求	与同任务 ratings/users 及指标成组可见； MovieID 关系校验失败时不得标记为正式可用。
生命周期	正式manifest引用者保留到课程项目结束，无自动TTL或版本上限；不得被新任务覆盖。
对应P/D/T	P1、P2、P3；D1、D2；T1、T2。

清洗后的 users

项目	内容
数据角色	正式派生数据，提供匿名用户属性维度。
主存储与格式	HDFS /movielens/clean/{dataset_version}/{task_id}/users/ ；目标格式为Parquet，未验证时回退文本；字段仅为 UserID、Gender、Age、Occupation、Zip-code ，邮编按字符串保存。
写入模式	先写 work 中本attempt的 clean/users/ ，采用后形成不可变稳定目录。
读取模式	MapReduce全量扫描、按 UserID 关联；目标Hive用于分组聚合。
一致性要求	与同任务 ratings/movies 及指标成组可见；不得跨任务拼接三类清洗数据。
生命周期	正式manifest引用者保留到课程项目结束，无自动TTL或版本上限；候选按统一流程清理。

项目	内容
对应P/D/T	P1、P2、P3；D1、D2；T1、T2。

清洗前/后五维质量指标

项目	内容
数据角色	正式派生结果和报告证据，覆盖Accurate、Complete、Unique、Up-to-date、Consistent。
主存储与格式	HDFS /movielens/metrics/{task_id}/pre/ 与 post/ ；JSON Lines每行一条 (task_id, stage, dimension) 指标，字段至少含 task_id, attempt_id, dataset_version, rule_version, stage, dimension, score, numerator, denominator, invalid_count 。
写入模式	各阶段先写`work/{task_id}/{attempt_id}/metrics/pre
读取模式	Agent/报告按 task_id 读取；Hive按 task_id、stage 分区并逐行解析JSON Lines，普通列包含其余字段。
一致性要求	pre 与 post 必须来自同一任务并分别绑定原始、清洗版本；缺维度、版本或规则错配均不可见。
生命周期	正式manifest引用者保留到课程项目结束，无自动TTL或版本上限；候选按统一流程清理。
对应P/D/T	P1、P2、P3；D1、D2；T1、T2。

清洗规则版本（ rule_version ）

项目	内容
数据角色	权威处理定义及血缘元数据，不是数据内容副本。
主存储与格式	不可变规则清单保存于 /movielens/rules/{rule_version}/manifest.json ，至少记录规则参数、评分公式、必要的实现版本和校验和；B侧MySQL任务记录仍只保存 rule_version 。
写入模式	新规则生成新版本，只追加不覆盖；任务创建时按 rule_version 固定引用。
读取模式	按 rule_version 定位并校验规则清单，处理任务读取其规则参数、评分公式和实现版本。
一致性要求	已启动任务的规则引用不可变；同名版本内容和校验和不得变化，正式可见前校验任务引用与候选产物记录一致。
生命周期	所有rules版本保留到课程项目结束，无自动TTL或版本上限。
对应P/D/T	P2、P3；D1、D2；T1。

数据版本（ dataset_version ）

项目	内容
数据角色	原始快照的权威版本标识和全部派生产物的血缘入口。
主存储与格式	使用 /movielens/raw/{dataset_version}/manifest.json 描述该版本包含的三个原始文件；B侧MySQL任务记录只保存版本值。
写入模式	每次原始快照登记一个新版本，只追加不覆盖；清洗任务只引用已校验版本。
读取模式	按版本确定manifest及原始文件路径，按版本查询相关任务、清洗结果、指标和报告。
一致性要求	一个版本必须唯一对应确定的三文件集合；文件内容变化必须产生新版本，不能复用旧标识。
生命周期	所有正式raw版本保留到课程项目结束，无自动TTL或版本上限。
对应P/D/T	P1、P2、P3；D1、D2；T1。

四个标识统一按以下关系使用： dataset_version 标识已校验原始快照， rule_version 标识不可变规则集合， task_id 标识绑定这两个版本及时间边界 train_cutoff_t1、validation_cutoff_t2 的一次逻辑任务， attempt_id 标识一次执行或重试，即 task_id → (dataset_version, rule_version, train_cutoff_t1, validation_cutoff_t2)、 attempt_id → task_id 。创建任务时必须校验 train_cutoff_t1 < validation_cutoff_t2 ；四项输入以MySQL governance_task 为权威，创建后不可变，重试沿用，任一变化均新建任务。publish manifest保存四标识及两个时间边界的审计快照，发布前与MySQL校验一致；clean行不重复保存时间边界。技术选型T1/T2与这两个时间边界字段不是同一概念。

课程阶段统一生命周期：raw、rules及被正式manifest引用的quarantine/clean/metrics/reports和publish manifest全部保留到课程项目结束，不设自动TTL或版本上限；work候选仅在任务终态且排障完成后删除，失败staging仅在确认未形成正式版本后删除。删除流程为“检查MySQL → 检查manifest → 确认非正式对象 → 人工删除并记录结果”；Hive元数据可重建，但 DROP TABLE 不得删除HDFS权威文件。

Hadoop任务状态、日志和失败信息

项目	设计内容
数据角色	MySQL中的业务任务状态是控制面权威元数据；YARN application/job/task状态是计算阶段的执行事实；失败摘要面向用户，完整错误堆栈和容器日志面向运维。
主存储与访问	MySQL保存task、attempt、当前阶段、失败摘要和YARN标识；YARN聚合日志保存到HDFS，MySQL只保存摘要和日志位置。
写入模式	总状态按 CREATED → QUEUED → RUNNING → VALIDATING → PUBLISHING → SUCCESS/FAILED 推进； RUNNING 内部以 CHECK/CLEAN/EVALUATE 表示当前阶段；执行和发布尝试分别追加记录。
读取模式	前端和Agent按task_id读取总状态、当前阶段、失败类型、简短原因和是否可手动重试； 运维再按application_id或attempt_id查看详细日志。
一致性	状态转换采用条件更新或版本号，旧尝试不得覆盖已确认状态；YARN阶段成功不等于整个业务任务SUCCESS；日志允许延迟到达，但不能改变业务终态。
生命周期	任务状态和发布关系至少与正式报告同生命周期；详细日志按配置清理，删除前保留失败摘要和证据失效标记。
对应来源	P4、P5、D3、T3、T4。

当前只实现用户触发的手动重试。计算失败时创建新的计算attempt；结果已经校验但发布失败时，只创建新的发布attempt并复用已有产物，不重新执行检查、清洗和评估。自动重试的次数、间隔和错误分类留待链路稳定后升级。

面向用户的报告、样例和查询结果

项目	设计内容
数据角色	正式报告和质量摘要正式派生结果；异常样例是解释证据；查询响应或缓存不是新的权威副本。
主存储与访问	HDFS /movielens/reports/{task_id}/ 保存被采用的不可变报告和大型样例； publish/{result_id}/manifest.json 仅记录结果版本、稳定路径和校验信息，不保存大产物。MySQL保存published_result，其中 manifest_path 决定正式可见性， report_path 可指向稳定reports目录。
写入模式	报告和大型样例先写 work/{task_id}/{attempt_id}/reports/ ，采用后进入稳定reports目录；形成并校验稳定对象与manifest后，MySQL事务插入published_result、设置accepted_attempt_id并切换SUCCESS。
读取模式	按task_id或result_id先读取MySQL manifest_path ，再按manifest路径读取reports、quarantine、clean或metrics稳定对象；报告可直接使用 report_path 。禁止扫描候选目录或复制大产物到publish。
一致性	仅当published_result有效且任务为SUCCESS时可见。MySQL登记失败时，已形成的稳定对象和manifest仍不可见，可供重试发布或确认无引用后清理。
生命周期	被正式manifest引用的reports保留到课程项目结束，无自动TTL或版本上限；work候选按统一人工删除流程处理，缓存可失效重建。
对应来源	P5、P6、D4、T4，并与A的D2、T1、T2衔接。

success 表示MySQL已完成正式发布并可由Agent/前端查询，不以网络响应或后续Hive分区是否登记成功为判断条件。

B侧摘要表模型

```
governance_task(  
    task_id PK, dataset_version, rule_version,  
    train_cutoff_t1, validation_cutoff_t2,  
    status, current_stage, accepted_attempt_id,  
    state_version, failed_stage, failure_type,  
    failure_code, failure_message, retryable,  
    created_at, started_at, finished_at  
)  
  
task_attempt(  
    attempt_id PK, task_id FK,  
    attempt_type, parent_attempt_id,  
    yarn_application_id, status, retry_no,  
    input_path, candidate_path, log_path,  
    started_at, finished_at  
)  
  
published_result(  
    result_id PK, task_id UNIQUE,  
    accepted_attempt_id UNIQUE, publish_token UNIQUE,  
    manifest_path, report_path, published_at  
)
```

3.3 课堂技术与候选方案

存储与访问模式、HBase、Hive及其他访问层

存储形态与访问模式

为避免宽表跨页，存储形态改为逐项纵向比较。

行存（如MySQL InnoDB）

项目	内容
擅长的访问模式	按主键点查、小范围更新、事务和唯一约束。
主要限制	扫描少数列时仍需读取完整行，不适合把大文件作为事务记录保存。
本系统结论	仅由B侧保存task、attempt和发布清单等小型控制元数据，不保存MovieLens批量权威数据。

列存文件（Parquet/ORC）

项目	内容
擅长的访问模式	只读取所需列、压缩编码、批量过滤和聚合。
主要限制	不适合逐行随机更新；写入器、模式和引擎兼容性需验证。
本系统结论	clean目标采用Parquet；ORC保留为Hive重度使用时的候选，不同时维护两份权威格式。

倒排索引（Elasticsearch）

项目	内容
擅长的访问模式	标题、错误原因、日志等文本的关键词检索和相关性排序。
主要限制	索引是派生副本，写入与刷新带来一致性和运维成本，不适合事务真相或批量全表聚合。
本系统结论	当前没有全文检索硬需求，不引入；未来出现大规模标题或日志全文搜索时从HDFS或MySQL受控构建可重建索引。

Text/JSON Lines

项目	内容
擅长的访问模式	原文保真、人工检查、流式逐行解析和跨工具交换。
主要限制	类型与模式约束弱，列裁剪和压缩效率低。
本系统结论	raw保留原始 .dat ； quarantine与metrics采用JSON Lines； Parquet链路未验证时clean回退为有明确模式的文本。

从存储抽象看，**Block**是HDFS内部的分布与容错单位，不能作为业务版本直接查询；**文件/目录**提供Hadoop可切分的批量输入输出及清晰版本边界，是当前主形态；**对象存储**以对象键和API提供持久化，适合存算分离和弹性计算，但缺少当前HDFS数据本地性，且提交、一致性、网络费用与凭据管理需另行验证。因此本轮不同时维护HDFS和对象存储两份权威数据。

事务负载与分析负载分开处理：任务状态、采用哪个attempt及发布唯一性属于小数据事务，由B侧MySQL负责；原始、异常、清洗数据和指标由HDFS保存、MapReduce处理，其中仅clean三表和metrics目标由Hive提供SQL访问。权威边界仍是HDFS中的批量数据和MySQL中的控制元数据，Hive Metastore、未来HBase或Elasticsearch均不得自行成为另一份业务真相。

HBase机制与是否纳入

- **HMaster**负责表和Region管理、负载均衡及故障协调，不承载普通数据读写；**RegionServer**服务客户端读写并管理多个**Region**。表按RowKey有序范围切为Region，Region再按Column Family形成**HStore**。
- 写入先追加到**WAL**以便故障恢复，再进入内存中的**MemStore**；刷盘后形成不可变、有序的**HFile**，后台Compaction合并文件。因此HBase适合按键低延迟读写和持续增量更新，但会引入WAL、刷盘、Compaction、Region分裂及集群运维成本。
- **RowKey**决定排序、范围扫描和Region负载；**Column Family**是物理存储与压缩配置边界，应少而稳定；单元格的**Timestamp**支持多版本，但版本保留必须显式限制，不能代替本系统的 dataset_version/task_id 业务血缘。

当前访问模式以一次导入、不可变版本、全量扫描和批量聚合为主，没有大量毫秒级RowKey点查、持续随机更新或稀疏宽表需求；任务/发布点查已由MySQL承担。因此本轮**不纳入HBase**，也不为不存在的在线负载增加一套权威副本。

若未来出现按用户/电影持续写入并在线查询的明确需求，可将HBase作为HDFS权威数据的可重建服务副本：RowKey采用散列前缀加实体类型与ID（如 hash(UserID)#U#UserID 或 hash(MovieID)#M#MovieID ）分散热点；列族保持少量稳定集合，例如 d 保存查询字段、 m 保存 dataset_version/task_id/source_path ；Timestamp仅保留经容量评估的最近版本，正式业务版本仍以显式列标识；批量导入需预分区并监控Region大小、请求倾斜和Compaction。只有在线延迟、吞吐和更新频率实测证明Hive/MySQL边界不足时才落实该方案。

Hive与其他访问层

Hive的**表**用模式将文件解释为行列；**外部表**执行 DROP TABLE 默认只删Metastore元数据，但Hive 4.0起设置 external.table.purge=true 会同时删除底层数据，因此本系统保持purge关闭，并以HDFS权限保证DROP不得删除权威文件。**Metastore**保存库表、字段、分区和位置，可重建且不替代HDFS文件或MySQL发布边界。**分区**按目录键裁剪扫描；**分桶**按列哈希拆文件，仅在稳定连接/抽样模式和足够规模下采用；**压缩**降低I/O，但须与引擎、格式兼容。

具体Hive落地以3.5 T2为唯一完整记录：仅覆盖已发布的clean三表和metrics；metrics按 task_id、stage 分区并逐行解析JSON Lines，当前不分桶。稳定对象与manifest校验后先由MySQL事务发布，成功后异步登记Hive分区；登记失败不回滚SUCCESS，可重试并允许短暂查询滞后，Agent始终走MySQL + manifest。

最终职责如下：**Hive**仅负责clean三表和metrics的SQL扫描、聚合与历史比较；**MySQL published_result/SUCCESS是唯一发布边界**；**HBase**因缺少在线宽列点查/更新负载而不选；**Elasticsearch**因缺少全文搜索需求而不选。Hive元数据及未来服务副本/索引均可重建，权威数据仍保持在HDFS/MySQL既定边界。

HDFS角色与读写

- **NameNode**维护命名空间、文件到Block的映射和Block位置等元数据，不传输全部文件内容。
- **DataNode**保存实际Block，响应客户端读写，发送心跳和BlockReport，并执行Block创建、删除或复制。
- **Block与副本**用于分布式存储和节点故障容忍，大小及副本数应按环境配置。
- **Secondary NameNode**合并fsimage与edits形成检查点，不是NameNode热备。

读取：客户端 → NameNode查询Block位置 → 客户端直接从就近DataNode读取
写入：客户端 → NameNode请求目标 → 客户端沿DataNode管线写入并形成副本 → 完成文件

B側HDFS目录边界

/movielens/

raw/.staging/{dataset_version}/ # T1: 上传校验暂存, 失败后人工清理

raw/{dataset_version}/ # T1: 原始.dat与manifest.json

rules/{rule_version}/manifest.json # T1: 独立不可变规则目录, 非数据区

quarantine/{task_id}/ # A负责异常数据设计

clean/{dataset_version}/{task_id}/ # A负责清洗数据设计

metrics/{task_id}/pre|post/ # A负责指标格式

reports/{task_id}/ # B: 被采用的报告与大型样例

work/{task_id}/{attempt_id}/ # B: 隔离的候选输出

publish/{result_id}/manifest.json # B: 仅结果清单、路径与校验信息

logs/yarn/{application_id}/ # B: 聚合日志

work/task/attempt 隔离多个执行尝试; 被采用的大对象进入quarantine/clean/metrics/reports稳定目录, publish只保存manifest。结果服务以MySQL published_result.manifest_path 判断可见性并解析稳定路径; 任务状态不写成HDFS小文件。

MapReduce处理链路

Job A: 清洗前质量检查与评分

Map逐记录检查 → 可选Combine局部计数 → Partition/Shuffle/Sort → Reduce形成指标

Job B: 数据清洗

Map逐记录标准化和合法性处理

仅在全局去重或跨记录规则确有需要时进入Shuffle/Reduce

Job C: 清洗后质量检查与评分

复用Job A的指标定义, 形成可比较结果

发布: 稳定对象+manifest校验 → MySQL事务登记published_result/accepted_attempt_id/SUCCESS → 异步登记Hive分区

环节	用途	使用边界
Map	解析、字段检查、逐行清洗和局部统计	不直接写正式结果或业务终态
Sort/Shuffle	汇集相同指标键、去重键或聚合键	仅在跨记录汇总时使用, 并记录Shuffle指标
Combine	减少可聚合计数的网络传输	是可选优化, 不能依赖其执行保证业务正确性; 仅用于满足结合律和交换律的操作
Partition	决定中间键进入哪个Reduce	相同键必须稳定进入同一分区, 并监控热点分区
Reduce	全局计数、去重或按键聚合	数量过少可能形成长尾, 过多会增加任务和小文件; 参数待实测

Hadoop默认文件输出提交实现先写任务尝试工作区, 再由OutputCommitter提交单个作业输出。它不保证Job A、B、C及多个稳定目录整体原子, 因此T4先校验稳定对象和只含引用的manifest, 再由MySQL事务控制可见性; 后续Hive登记失败仅造成分析查询滞后。框架task attempt与业务attempt_id属于不同层级; 计数器也不能识别用户重复提交的两个独立业务任务。

是否纳入本系统

纳入HDFS与MapReduce: 实验要求Agent调用Hadoop, 工作负载属于批量扫描、清洗和聚合。当前不假定多DataNode、NameNode HA或机架拓扑, 也不预设Block大小、Reduce数量、超时和重试次数。

3.4 工业界演进：YARN到容器化、托管与弹性计算

七项要求追踪

要求	本方向结论
对应P和D	P4/D3: 资源争用、长尾、观测和异步执行; P5/D3/D4: 失败尝试、日志和发布; P6/D4: 迁移后仍保持状态、结果和证据一致。

要求	本方向结论
数据与读写路径	处理原始数据、候选清洗结果、质量指标和报告等批量对象；YARN直接读写HDFS，未来容器化/托管计算通过稳定持久存储交换输入输出。
与现有组件交换	Agent经任务接口提交；后端按task_id/attempt_id读输入、写候选，采用后写稳定目录和仅含引用的manifest；发布者登记MySQL，结果服务据 manifest_path 读取正式结果。
权威数据	T1选定的HDFS稳定目录保存权威原始/规则及被采用的数据、报告和大型样例，publish仅存manifest；MySQL保存权威业务状态并决定正式可见性，调度状态、日志、缓存和迁移副本均无发布权。
引入条件	依赖隔离、任务峰谷、排队延迟、静态资源成本或控制面可用性成为主要问题时才迁移；当前没有实测阈值。
候选比较	比较长期HDFS+YARN、Kubernetes/容器化任务和托管弹性服务；当前选YARN，后两者作为有条件演进路线。
新增风险	平台运维或云费用、远程读写和网络成本、数据本地性减弱、提交语义变化、厂商依赖、状态映射和迁移期一致性。

路线比较

长期HDFS+YARN

项目	内容
优点	与课程和MapReduce最匹配；可利用HDFS本地性；机制清晰。
风险与限制	节点容量较固定；可能产生空闲成本；需自行维护集群。
本系统判断	当前目标架构。

Kubernetes或YARN容器运行时

项目	内容
优点	镜像隔离、环境可复现，可与既有容器平台统一。
风险与限制	Kubernetes Job不自动提供MapReduce Shuffle和HDFS本地性；存储、网络、日志与安全集成复杂。
本系统判断	当前不引入；组织已有成熟平台且依赖冲突突出时重评。

托管/弹性/Serverless服务

项目	内容
优点	降低控制面运维，适合潮汐和临时任务。
风险与限制	云费用、启动延迟、厂商依赖、网络传输及可观测模型变化。
本系统判断	生产化且静态成本或排队问题突出时评估。

迁移前后保持task_id、attempt_id、输入版本、候选输出、稳定路径和manifest契约。计算平台只生成候选结果；大产物进入稳定目录，publish不复制，MySQL发布者仍掌握唯一正式发布权。是否迁移应依据队列等待、启动时间、节点利用率、单位任务成本、恢复时间和控制面可用性，而不是预设固定数据条数。

论文、Apache Hadoop/Kubernetes开源实现以及Amazon EMR Serverless、Google Dataproc等实际托管服务证明相关机制和路线真实存在，但不代表本项目已经部署，也不能直接照搬其费用、延迟或SLA。

3.5 技术选型记录

T1：HDFS版本化目录承担批量主存储

项目	内容
来源	P1、P3、D1，并关联P2、D2。

项目	内容
能力约束	批量文件需可切分顺序读取、按数据集/任务/版本定位；节点故障后不能把缺失对象当作有效结果；原始数据、可重算派生数据和正式证据按价值分级保护；正式版本不可覆盖。当前不预设副本数、恢复时限或纠删码策略。
候选技术	本地文件；HDFS；对象存储。格式子候选为原始Text、Parquet、ORC。
比较维度	存储候选比较节点故障容忍、Hadoop数据本地性、批量吞吐、版本隔离、恢复方式、部署与迁移成本；格式比较原文保真、模式与类型、列裁剪、压缩、MapReduce/Hive兼容性和随机更新能力。
最终选择	HDFS版本化分区目录作为批量主存储；raw保留原始 .dat ， clean目标采用Parquet，quarantine与metrics采用JSON Lines，reports保存报告和大型样例。ORC不与Parquet重复落一份权威数据。
落地方式	三个raw文件先上传 /movielens/raw/.staging/{dataset_version}/ ，校验齐全、大小、编码和校验和后最后写manifest，再同HDFS rename至 raw/{dataset_version} ；正式目录存在即拒绝覆盖，任务只读有效manifest，失败staging人工清理。rules只追加且定义评分公式。attempt派生数据先写work，采用后进入quarantine/clean/metrics/reports稳定目录；metrics按每行一条 (task_id, stage, dimension) 的JSON Lines写入3.2所列字段。publish manifest仅记录 dataset_version、rule_version、task_id、attempt_id 、两个时间边界审计快照、稳定路径和校验信息，不复制大产物。
选择理由	本地文件缺少跨节点容错和集群共享；HDFS与当前Hadoop批处理链直接衔接，并以Block、副本和目录提供大文件吞吐及故障恢复基础；对象存储更适合存算分离，但当前会额外引入网络、凭据和提交语义验证。Text最适合保留原文，Parquet相对Text适合clean的列裁剪、类型和压缩；ORC能力相近但当前没有Hive专属优化证据，避免双格式。
未满足项与补救	当前未确认多DataNode、副本恢复、Parquet写入及各引擎兼容性；实验先使用HDFS文本和MapReduce直接读取。HDFS目录不能提供跨对象业务事务，由manifest校验和MySQL发布控制补足；课程阶段正式对象保留至项目结束，work/staging按3.2统一人工流程清理。
替换条件	单机实验且无需容错时可暂用本地文件；计算迁往弹性/托管平台、数据本地性收益消失或跨集群共享成为硬需求时重评对象存储；Hive工作负载和ORC实测收益稳定高于Parquet且迁移可控时重评格式；冷历史容量使副本成本成为主要开销时评估EC/分层存储。

T2：Hive外部表承担HDFS批量SQL访问

项目	内容
来源	P2、P3、D2，并关联P1、D1。
能力约束	需按数据版本、任务和规则定位已采用数据，支持大范围扫描、聚合和历史比较；正式数据保持不可变，访问层不得把候选误作正式结果；事务状态和大文件分析必须分工。
候选技术	Hive外部表；HBase；MySQL；Elasticsearch。
比较维度	批量扫描与聚合、RowKey点查和随机更新、全文检索、事务与一致性、是否复用HDFS权威文件、分区裁剪、运维成本及失败后可重建性。
最终选择	目标采用Hive外部表作为HDFS批量SQL访问层，按 dataset_version 等已知查询键分区，当前不分桶；MySQL继续只保存B侧任务与发布控制元数据；当前不引入HBase和Elasticsearch。
落地方式	仅为clean三表及metrics建立外部表，raw由MapReduce解析；LOCATION只指向已发布稳定目录。clean按 dataset_version、task_id 分区；metrics按 task_id、stage(pre/post) 分区，以明确schema和兼容JSON SerDe逐行解析JSON Lines，其余字段为普通列。MySQL发布成功后异步登记分区；失败可重试且不回滚SUCCESS。外部表保持 external.table.purge=false 并以HDFS权限禁止DROP删除权威文件；Parquet未验证时MapReduce直读文本。
选择理由	Hive复用HDFS文件并提供批量扫描、关系查询和聚合SQL；HBase的低延迟按键读写、MySQL的事务点查、Elasticsearch的全文检索均不匹配当前不可变批分析。外部表默认 DROP TABLE 只删元数据，较内部表更符合数据/元数据分离，但该安全边界仍依赖禁用purge和HDFS权限。
未满足项与补救	Hive/Metastore、Parquet及JSON SerDe、分区登记尚未验证；先以MapReduce直读文件。Hive登记允许短暂滞后，Agent始终走MySQL+manifest；合并输出并调整分区键控制小文件。误设purge仍可删除数据，故配置检查、最小权限及统一人工删除流程缺一不可。
替换条件	若出现持续随机更新、按用户/电影的低延迟高吞吐点查且MySQL不适合，评估HBase；若出现标题、异常或日志的相关性全文搜索，评估Elasticsearch派生索引；若主要需求变为小数据事务查询，继续由MySQL承担；若Hive引擎/Metastore运维成本超过SQL收益，则保留HDFS+MapReduce直接访问。

T3：Hadoop MapReduce on YARN承担治理批处理

项目	内容
来源	P4、P5、D3。
能力约束	面向批量治理任务提供可切分、可观测、可恢复的异步执行；支持跨记录聚合所需的Shuffle，区分业务attempt与框架task attempt，记录阶段、分片、计数器、日志和失败原因；当前以手动重试为主，失败或迟到尝试不得直接发布。 当前只验证过Hadoop本地模式，不能把YARN写成已部署事实。
候选技术	单进程或Hadoop本地脚本；Hadoop MapReduce on YARN；Kubernetes Job；托管或Serverless大数据计算服务。
比较维度	输入切分与Shuffle、HDFS数据本地性、失败重执行与尝试隔离、阶段/分片状态、计数器与日志、批任务启动开销、课程匹配、部署运维和弹性成本。
最终选择	目标架构采用MapReduce on YARN；当前实验仅验证Hadoop本地模式，YARN运行链待后续验证。
落地方式	任务接口先在MySQL创建逻辑任务和业务attempt，再提交Job A清洗前检查评分、Job B清洗、Job C清洗后复评；保存YARN application/job标识。作业读取有效raw/rules，写 work/{task_id}/{attempt_id} 候选目录；YARN/MapReduce进度、计数器和日志映射到业务状态，日志聚合到HDFS；全部阶段完成后进入T4校验发布。逐行处理优先Map-only，跨记录聚合才使用Shuffle/Reduce，Combine仅用于不影响正确性的可结合、可交换统计。
选择理由	MapReduce原始论文和Hadoop官方机制直接支持输入切分、Shuffle、失败任务重执行和任务尝试；YARN提供资源调度与应用状态。该组合与MovieLens大数据集的批量检查、清洗和评分相符，也满足课程要求；本地脚本缺少分布式恢复，Kubernetes Job本身不提供MapReduce语义，托管服务在当前实验中缺少成本和平台依据。
未满足项与补救	YARN提交、状态和日志链路尚未实测；批任务启动及多阶段落盘开销较高；数据倾斜、慢任务和静态集群忙闲不均不会自动消失。当前保留Hadoop本地模式回退并采用异步接口；后续验证YARN链路，记录阶段耗时、分区数据量、Shuffle量和队列等待，再调整分区、Reduce数量和可用的局部聚合；不预设未经实测的参数。
替换条件	出现必须满足的低延迟或持续增量处理需求；多阶段落盘成为主要瓶颈；任务峰谷使静态集群成本或排队持续违反SLA；或者组织已有成熟Kubernetes/托管平台，并能维持task、attempt、稳定路径和manifest契约时，重新比较流处理、容器化或托管计算。


T4：MySQL事务发布记录 + HDFS稳定对象、manifest和日志

项目	内容
来源	P5、P6、D4。
能力约束	隔离候选与正式结果；按task/attempt查询和更新状态；旧尝试不能覆盖已确认状态；重复发布只生效一次；发布需绑定dataset、rule、task、attempt、时间边界和各版本化产物；Agent只能读取正式结果。大对象和完整日志不能塞入事务控制库，当前仅要求手动重试发布。
候选技术	仅用HDFS目录或JSON状态文件；HBase；MySQL InnoDB + HDFS稳定对象/manifest/日志；仅依赖YARN状态和History Server。
比较维度	ACID事务、主键和唯一约束、条件更新、task_id点查、跨尝试并发、不可变大对象吞吐、日志容量、跨系统一致性、与结果服务集成及运维成本。
最终选择	MySQL InnoDB保存task、attempt、published_result和少量证据；HDFS的quarantine/clean/metrics/reports稳定目录保存被采用对象，publish目录只保存manifest，另由HDFS保存候选和YARN日志。
落地方式	创建任务时校验 train_cutoff_t1 < validation_cutoff_t2 并与dataset/rule版本一同写入governance_task，创建后不可变，重试沿用，变化则新建任务。稳定对象和manifest校验通过后，发布前核对manifest中的两个时间边界审计快照，再由MySQL事务登记published_result、accepted_attempt_id和SUCCESS；这是唯一发布边界。成功后异步登记Hive分区，失败不回滚SUCCESS且可重试；Agent仍按 manifest_path 读取， report_path 可指向reports。
选择理由	InnoDB官方支持事务、回滚、崩溃恢复、主键和唯一约束，适合任务状态、条件更新与幂等发布；HDFS适合大体量顺序读写和不可变对象。仅用HDFS难以直接表达事务化状态转换和唯一发布，HBase当前规模与关系约束不占优，YARN History Server只保存执行历史而不了解业务版本和发布关系。MySQL与HDFS按访问模式和一致性要求分工。
未满足项与补救	HDFS与MySQL没有跨系统原子事务，MySQL登记失败会留下不可见稳定对象或manifest；Hive异步登记失败会造成短暂分析滞后；单实例MySQL存在容量和可用性上限。当前采用“先完成并校验稳定对象和manifest，

项目	内容
	再以MySQL事务发布”，发布失败只手动重试发布；Hive登记单独重试且不回滚SUCCESS；未登记对象按“检查MySQL→检查manifest→确认非正式→人工删除并记录”处理。
替换条件	任务状态写入量或可用性超过单实例关系数据库能力；未登记对象、一致性故障或人工清理成本成为主要风险；需要跨系统强原子发布；证据模型演化为海量宽列访问；或T1/T2提供能够等价满足事务点查、条件更新和幂等约束的统一元数据层时，重新评估数据库高可用、自动协调或替代存储。

3.6 落地架构图

最终组件架构与数据流



图中实线表示数据对象流动，虚线表示提交、查询、调度、状态、元数据、校验、rename、登记或清理等控制流。T1/T2是技术选型编号，图中的 t1/t2 是训练与验证时间边界，两者含义不同。绿色节点为实验必须实现，蓝色为设计建议，黄色虚线节点为待验证目标，灰色节点为当前未选的远期方案。

权威性与非功能边界

- T1选定的HDFS稳定目录保存raw、rules及被采用的异常、清洗、指标、报告和大型样例；publish目录只保存manifest，课程阶段正式对象均保留至项目结束。

- HDFS `work` 和`raw staging`是内部临时目录；MySQL `published_result/SUCCESS`决定正式可见性，结果服务只读取manifest引用的稳定对象，Hive登记滞后不影响Agent。
- YARN状态、计数器和日志是执行证据，不替代业务SUCCESS状态；查询响应和缓存只是派生数据。
- Agent只能调用任务和结果接口，不能直接遍历候选目录。
- 监控至少覆盖阶段耗时、分区处理量、Shuffle数据量、失败次数和队列等待；日志由HDFS承载，MySQL保存摘要和位置。
- Secondary NameNode不承担高可用；NameNode HA、MySQL高可用和更强跨系统协调按实际可用性要求后续评估。

分阶段落地与回退

阶段	采用能力	暂不采用	回退方式
当前实验	Hadoop本地模式；task固化版本/时间边界； raw staging校验；JSON Lines指标； work候选；publish仅存manifest； MySQL唯一发布	自动重试、YARN已部署假设、 Kubernetes、托管弹性、 跨系统强事务	计算失败人工重跑；MySQL发布失败仅重试发布， 未登记对象不可见；临时对象经引用检查后人工删除
链路完善	验证MapReduce on YARN； 异步Hive分区登记与重试；YARN日志聚合； 人工清理记录；分区指标	流处理和复杂跨系统事务	Hive登记失败不回滚SUCCESS， Agent继续走MySQL+manifest； 保留稳定路径和manifest契约
规模增长	按证据增加高可用、队列隔离和阶段恢复； 评估容器化或托管弹性	未经压测的组件堆叠	计算后端保持稳定契约， 可切回YARN而不改变Agent与结果服务接口

参考资料

1. Apache Hadoop, [HDFS Architecture](#).
2. Apache Hadoop, [HDFS Users Guide](#).
3. Apache Hadoop, [MapReduce Tutorial](#)及[OutputCommitter API](#).
4. Dean and Ghemawat, *MapReduce: Simplified Data Processing on Large Clusters*, OSDI 2004.
5. Apache Hadoop, [YARN Architecture](#)、[YARN Docker Runtime](#)及[Apache Hadoop开源仓库](#).
6. Vavilapalli et al., *Apache Hadoop YARN: Yet Another Resource Negotiator*, SoCC 2013.
7. MySQL, [InnoDB Introduction](#)及PRIMARY KEY/UNIQUE约束.
8. Kubernetes, [Jobs](#)及[Kubernetes开源仓库](#).
9. Amazon, [EMR Serverless User Guide](#).
10. Google Cloud, [Dataproc Autoscaling](#).
11. Apache HBase, [Apache HBase Reference Guide: Architecture](#).
12. Apache Hive, [LanguageManual DDL](#)及[LanguageManual Types](#).
13. Apache Parquet, [Documentation](#)；Apache ORC, [Documentation](#).